

ANTHERA

x APERTUS

STRATEGIA SOVEREIGN EUROPEAN AI

VERSION

v1.0

DATE

14 Maggio 2026

AUTHOR

ANTHERA Systems

CLASSIFICATION

Strategic / Confidential

European data deserves European AI.

Documento strategico di adozione di Apertus come motore AI sovrano dell'ecosistema ANTHERA Systems.

Sovereign European AI come Cuore dell'Ecosistema ANTHERA

Versione: 1.0
Data: 14 Maggio 2026
Autore: ANTHERA Systems
Destinatari: Founder, Investor, Compliance Officer, Solution Architect, Procurement IT

Executive Summary

ANTHERA Systems sceglie **Apertus** — il Large Language Model open-source sviluppato da **ETH Zurich + EPFL + CSCS** (Swiss National Supercomputing Centre) — come **motore AI di default** per tutti i prodotti del proprio ecosistema, a partire da **GOVERN.AI**.

Questa scelta non e tecnica, ma **strategica e identitaria**: i dati europei restano in Europa, l'intelligenza che li elabora e europea, e l'intera supply chain AI e trasparente, ispezionabile e conforme.

In una frase: *"European data deserves European AI."*

1. Perche Apertus — Il Razionale ANTHERA

1.1 Il problema attuale

Le imprese europee che adottano AI affrontano un dilemma:

Esigenza	LLM US (GPT/Claude)	Conseguenza
Dati personali GDPR	Trasferimento extra-UE	Data Processing Addendum complesso, rischio Schrems III
Sovranita dati DORA	Outsourcing critico	Notifica all'autorita, contingency plan
Trasparenza EU AI Act Art. 13/53	Training data segreto	Impossibile attestare provenienza
Resilienza NIS2	Dipendenza supplier USA	Single point of failure geopolitico
Procurement PA	Cloud Act USA	Esclusione da gare strategiche

1.2 La risposta ANTHERA

Apertus risolve tutti questi attriti **in un colpo solo**:

- **100% trasparente** (pesi + dati + ricetta di training pubblici)
- **Sovrano EU/CH** (training su supercomputer Alps a Lugano, hosting EU)
- **Multilingua nativo** (italiano, tedesco, francese, romancio al pari di inglese)
- **Apache 2.0** (zero vendor lock-in, free per uso commerciale)
- **Allineato a EU AI Act** by design (non retrofit)

1.3 Il messaggio commerciale ANTHERA

*“I tuoi dati sono europei. La governance è europea. L'AI che li elabora deve esserlo anche essa.”**

Questa narrativa diventa **moltiplicatore di vendita**:

- Banche italiane (vincoli Banca d'Italia + ECB)
- Pubblica Amministrazione (procurement AGID, sovranità)
- Sanità (dati paziente, art. 9 GDPR)
- Difesa / infrastrutture critiche (NIS2 supplier chain)
- Settore pubblico CH/EU (Public AI Inference Utility Swisscom)

2. Cos'è Apertus — Scheda Tecnica

2.1 Identità

Attributo	Valore
Nome	Apertus (dal latino "aperto")
Sviluppatori	ETH Zurich, EPFL, CSCS (Swiss National Supercomputing Centre)
Sponsor	Swiss Confederation, Swiss AI Initiative
Rilascio	Settembre 2025
Licenza	Apache 2.0 (commercial-friendly)
Sito	apertus.ai
Modelli disponibili	Apertus-8B-Instruct, Apertus-70B-Instruct
Lingue supportate	1.800+ (italiano, tedesco, francese, romancio nativi)
Trained on	Supercomputer Alps (CSCS Lugano) — 10.000+ NVIDIA GH200
Trasparenza	Pesi + dataset + training recipe + code completamente pubblici
Compliance	EU AI Act Article 13/53 ready, GDPR-friendly

2.2 Caratteristiche distintive

- **Fully Open**: è il primo LLM di scala enterprise dove **tutto** è pubblico (non solo i pesi)

- **Multilingua bilanciato:** a differenza di GPT/Claude (90% inglese), Apertus tratta italiano e tedesco come lingue di prima classe
- **Auditabilità:** ogni decisione del modello è tracciabile fino al dato di training
- **Indipendenza geopolitica:** fuori dal perimetro del Cloud Act USA, del CHIPS Act, di sanzioni extraterritoriali

2.3 Posizionamento vs concorrenza


Caratteristica	GPT-4o	Claude 3.5	Gemini 2.0	**Apertus 70B**
Licenza	Proprietaria	Proprietaria	Proprietaria	**Apache 2.0**
Pesi pubblici	No	No	No	**Sì**
Training data pubblico	No	No	No	**Sì**
Sovranità EU/CH	No (US)	No (US)	No (US)	**Sì (CH)**
Multilingua IT first-class	Parziale	Parziale	Parziale	**Sì**
EU AI Act Art. 13 ready	Completo	Completo	Completo	**Nativo**
Cloud Act USA	Sì	Sì	Sì	**No**
Self-hosting	No	No	No	**Sì**
Costo	Alto	Alto	Medio	**Free (infra cost only)**

3. Architettura di Integrazione ANThERA

3.1 Principio: abstraction layer

ANTHERA già utilizza **litellm** in tutti i prodotti come **layer di astrazione LLM-agnostic**. Questo rende l'adozione di Apertus **trasparente** dal punto di vista del codice applicativo.

```
■ APPLICAZIONE (es. GOVERN.AI) ■
■ routes/chat.py -> ARIA Assistant ■
■
▼
■ litellm ■
■ Abstraction layer LLM-agnostic + streaming ■
■ ■
```



3.2 Switch via variabile d'ambiente

L'integrazione si limita a:

```
# backend/.env
LLM_PROVIDER=apertus
LLM_MODEL=apertus/apertus-70b-instruct
LLM_BASE_URL=https://api.publicai.swiss/v1
APERTUS_API_KEY=<chiave>
```

Zero modifiche al codice applicativo. Il routing avviene a livello di litellm.

3.3 Modalita operativa proposta (Dual Mode)

Per massimizzare flessibilita commerciale, ANTHERA suggerisce di esporre nella UI un **toggle "Sovereign Mode"**:

Modalita	Modello	Use case
Sovereign Mode (default)	Apertus 70B	Produzione, dati sensibili, clienti EU/CH
Performance Mode (opt-in)	GPT-4o / Claude	Task molto complessi, prototipi
Offline Mode	Apertus 8B via Ollama	Demo on-prem, ambienti air-gapped

Questa scelta diventa **argomento di vendita killer**: **"Vuoi sovranita totale? Sovereign Mode. Vuoi qualita massima? Performance Mode. La scelta e tua, in 1 click."**

4. Opzioni di Deployment — Passo Passo

4.1 Opzione A — Public AI Inference Utility (Swisscom) CONSIGLIATA

Scenario: SaaS produzione, zero ops, sovranita CH dichiarata.

Step:

- Registrarsi su publicai.swiss (Swiss Public AI Inference Utility, in beta)
- Ottenere API key
- Configurare:

```
LLM_MODEL=apertus/apertus-70b-instruct
LLM_BASE_URL=https://api.publicai.swiss/v1
APERTUS_API_KEY=<key>
```

- Verificare endpoint con curl di smoke test
- Riavviare il backend

Tempo: ~2 ore (incluso onboarding Swisscom)

Costo: pricing per token, in linea con OpenAI ma sovrano CH

Pro: zero infra, SLA enterprise, conformita CH/EU certificata

Contro: dipendenza singolo provider (mitigato dal fatto che e ente pubblico CH)

4.2 Opzione B — Hugging Face Inference Endpoints

Scenario: prototipazione veloce, pilota cliente.

Step:

- Account su `huggingface.co`
- Deploy "Apertus-70B-Instruct" su Inference Endpoints (regione EU: Frankfurt o Helsinki)
- Ottenere URL endpoint + token
- Configurare:

```
LLM_MODEL=huggingface/apertus-70b-instruct
LLM_BASE_URL=https://<endpoint>.eu-west-1.aws.endpoints.huggingface.cloud
HUGGINGFACE_API_KEY=<token>
```

Tempo: ~3 ore

Costo: ~2-4 USD/ora di GPU A100 attiva (auto-scaling)

Pro: deploy in 10 minuti, infra EU

Contro: HF e USA-based corporation (mitigato: hosting in EU + Apache license del modello)

4.3 Opzione C — Self-Hosted vLLM su GPU EU MAX SOVRANITA

Scenario: enterprise, banche, PA, clienti sensibili.

Step:

- Provisioning GPU EU: OVH (Strasburgo/Roubaix), Aruba (Italia), Open Telekom (DE), Scaleway (FR), o on-prem
- Hardware minimo: 2x NVIDIA H100 80GB (per 70B), 1x A100 40GB (per 8B)
- Installazione vLLM:

```
pip install vllm
python -m vllm.entrypoints.openai.api_server \
--model swiss-ai/Apertus-70B-Instruct-2509 \
--port 8000 \
--tensor-parallel-size 2
```

- Configurare GOVERN.AI:

```
LLM_MODEL=openai/apertus-70b-instruct
LLM_BASE_URL=http://<vllm-host>:8000/v1
OPENAI_API_KEY=dummy # vLLM accetta qualsiasi key
```

Tempo: 1-2 giorni (incluso setup GPU + benchmark)

Costo: ~3.000-8.000 EUR/mese GPU H100 dedicata (oppure CAPEX ~50k EUR on-prem)

Pro: sovranità totale, zero dipendenza esterna, latenza ottima

Contro: ops overhead, capex/opex GPU

4.4 Opzione D — Ollama On-Prem (Apertus 8B)

Scenario: demo locale, sviluppatori, ambienti air-gapped.

Step:

- Installare Ollama (`brew install ollama` o equivalente Linux)
- `ollama pull apertus:8b`
- `ollama serve` (porta 11434)
- Configurare:

```
LLM_MODEL=ollama/apertus:8b  
LLM_BASE_URL=http://localhost:11434/v1
```

Tempo: 30 minuti

Costo: zero (gira anche su MacBook M3 con 32 GB RAM)

Pro: demo offline, zero costi, privacy massima

Contro: solo 8B (qualità inferiore), non scalabile per produzione

5. Roadmap di Adozione ANTHERA

Fase 1 — GOVERN.AI (Q2 2026)

- Integrare Apertus come opzione configurabile in GOVERN.AI (~1 sprint)
- UI toggle "Sovereign Mode" nelle Settings
- Aggiornare documentazione + Investor Intro: "Powered by Sovereign European AI"
- Demo a pilota cliente banking IT con Sovereign Mode attivo

Fase 2 — Validazione produzione (Q3 2026)

- Selezionare 1 design partner enterprise per pilota Apertus 70B su Public AI Swiss
- Misurare: latenza, qualità risposte ARIA, soddisfazione utente
- Confronto blind A/B vs GPT-4o
- Pubblicazione case study

Fase 3 — Estensione a tutto l'ecosistema ANTHERA (Q4 2026 — Q1 2027)

- Default Apertus su ogni nuovo prodotto ANTHERA
- Retrofit prodotti esistenti se applicabile
- Partnership formale con Swiss AI Initiative / CSCS
- ANTHERA come "Apertus Premier Partner" (titolo proposto)

Fase 4 — Go-to-market sovranita (2027)

- Apertura mercato CH (Swisscom, UBS, Credit Suisse legacy, PA federale)
- Apertura mercato DE/AT (BaFin, Bundesbank, Vienna Stock Exchange)
- Apertura mercato FR (CNIL, ACPR, settore difesa)

6. Compliance — Mappatura Apertus vs Normative

Normativa	Articolo	Come Apertus aiuta
EU AI Act	Art. 13 (Transparency)	Training data pubblico -> attestazione immediata
EU AI Act	Art. 53 (GPAI Models)	GPAI con technical documentation completa gia disponibile
GDPR	Art. 44 (Trasferimenti)	Hosting EU/CH -> nessun trasferimento extra-UE
GDPR	Art. 35 (DPIA)	DPIA semplificata grazie a trasparenza modello
DORA	Art. 28 (ICT Third-party)	Supplier EU/CH critico approvabile dal CdA
NIS2	Art. 21 (Supply Chain)	Supply chain sovrana, non US-dipendente
D.Lgs. 262	Internal Controls	Modello auditabile per Dirigente Preposto
ISO 42001	AI Management	Trasparenza modello = controllo lifecycle facilitato
Cloud Act USA	N/A	Apertus fuori giurisdizione USA

7. Costo Totale di Ownership (TCO) — Esempio

Scenario: GOVERN.AI in produzione con 50 utenti concorrenti, 100.000 query LLM/mese.

Voce	GPT-4o (OpenAI)	Apertus 70B (Public AI CH)	Apertus 70B (Self-host vLLM EU)
Costo modello	~3.000 EUR/mese	~2.000 EUR/mese	0 EUR/mese
Costo infra	0	0	~5.000 EUR/mese (2x H100)
Costo compliance	Alto (DPA, valutazioni)	Basso	Minimo
Ops overhead	Basso	Basso	Medio
TCO mensile	**~3.000 EUR + compliance**	**~2.000 EUR**	**~5.000 EUR**
TCO sovranita	Bassa	Alta	Massima

Voce	GPT-4o (OpenAI)	Apertus 70B (Public AI CH)	Apertus 70B (Self-host vLLM EU)
Vendor lock-in	Alto	Medio	Zero

8. FAQ

8.1 Apertus e davvero al livello di GPT-4o?

Apertus-70B è competitivo con **GPT-4-turbo / Claude 3.5 Sonnet** sui benchmark multilingua europei (Llama-3-Eval, EU-Truthful, ItaEval). E leggermente sotto GPT-4o su task molto complessi di reasoning, ma per i casi d'uso di ARIA (Q&A normativo, sintesi, guidance) la differenza è marginale e compensata dal multilingua nativo.

8.2 Quanto costa la migrazione tecnica?

Zero o quasi, grazie a litellm. Bastano 1-2 ore di un developer per testare l'endpoint Apertus e validare ARIA con qualche prompt rappresentativo.

8.3 E se Public AI Swiss avesse downtime?

Litellm supporta **fallback automatico**: configuriamo Apertus come primario e GPT-4o come fallback. Zero impatto sull'utente finale.

8.4 Posso usare Apertus per generare PDF/CSV?

Sì, esattamente come oggi con GPT. La generazione è gestita lato ReportLab/Python, non dal LLM. Il LLM serve solo per il ragionamento normativo di ARIA.

8.5 Apertus risponde in italiano correttamente?

Sì, eccellentemente. A differenza di GPT (che traduce dall'inglese internamente), Apertus tratta l'italiano come lingua di prima classe nel training. La qualità stilistica e legale italiana è superiore.

8.6 Possiamo addestrare un fine-tune su normative italiane?

Sì, Apertus è Apache 2.0 e i pesi sono pubblici. Possiamo fare LoRA fine-tune su corpus normativo italiano (codice civile, codice penale, GDPR, leggi finanziarie) per creare un **"ARIA Legal Italian Edition"**. Costo: ~5-10k EUR di GPU + 1 settimana di lavoro.

8.7 E se OpenAI lancia un modello migliore?

Litellm permette di scegliere modello **per ogni richiesta**. Non perdiamo nulla: avremo sempre la possibilità di usare il meglio del mercato come opt-in, ma il default sovrano EU resta Apertus.

8.8 Apertus può essere usato per i prodotti commerciali ANTHERA?

Sì, **Apache 2.0** consente uso commerciale illimitato. Nessun obbligo di rilascio del codice ANTHERA che usa Apertus.

9. Prossimi Passi Operativi

- **Valutazione Public AI Swiss:** registrazione, contatto Swisscom, ottenimento API key di test
- **Smoke test su GOVERN.AI** (ambiente dev): cambio variabili env, validazione streaming ARIA
- **Benchmark blind:** 20 prompt normativi -> confronto GPT-4o vs Apertus 70B -> scoring qualità
- **Decisione GO/NO-GO** entro fine Q2 2026
- **Roll-out production** Q3 2026 con UI toggle "Sovereign Mode"
- **Comunicazione esterna:** aggiornamento sito ANTHERA, press release "ANTHERA adotta Apertus"
- **Estensione a portfolio ANTHERA** Q4 2026

10. Conclusione

L'adozione di **Apertus** non è una scelta tecnica: è una **dichiarazione identitaria**.

ANTHERA Systems esiste per portare la sovranità digitale in Europa. Un prodotto di governance AI che gira su LLM US tradisce la propria missione. Con Apertus, ANTHERA diventa **end-to-end European**:

- **Dati europei** -> ospitati in EU/CH
- **Codice europeo** -> open source compliance-first
- **AI europea** -> Apertus, sviluppato e ospitato in Svizzera
- **Governance europea** -> conforme EU AI Act / GDPR / DORA / NIS2 per design

"Sovereign Control Plane for Enterprise AI, powered by Sovereign European AI."

Questa è la promessa che ANTHERA può mantenere — **a partire da oggi**.

Contatti

Angelo Anglani — Founder, ANTHERA Systems

- angelo.anglani94@gmail.com
- +39 342 754 8655
- linkedin.com/in/angelo-anglani

Riferimenti Apertus:

- apertus.ai
- huggingface.co/swiss-ai
- publicai.swiss (Swiss Public AI Inference Utility)
- ethz.ch / epfl.ch / cscs.ch

ANTHERA Systems — European data deserves European AI.

Documento strategico — 14 Maggio 2026 — v1.0